Alokácia investícií do finančných produktov

Obsah

Úloha 4: Alokácia investícií (4b) **2**
Cieľ úlohy . . . 2
Definícia optimalizačnej úlohy . . . 2
Postup riešenia . . . 3

Odovzdanie a hodnotenie **4**
Dokumentácia výsledkov (PDF) . . . 4
Obhajoba riešenia . . . 4

Odporúčané nástroje a technická realizácia **5**
Matlab . . . 5
Python . . . 5

Teoretické poznámky **6**
Formulácia úlohy, obmedzenia a význam fitness . . . 6
Pokutovanie a interpretácia rôznych prístupov . . . 7
Porovnávanie metód a čítanie grafov konvergencie . . . 7

Úloha 4: Alokácia investícií do finančných produktov (4b)

Cieľ úlohy

Pomocou genetického algoritmu (GA) navrhnite optimálnu alokáciu investícií do vybraných finančných produktov. Podstata úlohy, vrátane metód pokutovania, bola vysvetlená v prednáške. Vyriešte príklad s rešpektovaním všetkých uvedených ohraničení. Použite pôvodný GA a **samostatne** otestujte **tri** rôzne metódy pokutovania z prednášky. Pre každú metódu vykonajte výpočet zvlášť a **porovnajte ich vplyv** na konvergenciu fitness a na nájdené riešenie.

Definícia optimalizačnej úlohy

Firma chce investovať celkovo **10 000 000 EUR** do nasledujúcich produktov. Nech rozhodovacie premenné $x_1, \ldots, x_5$ vyjadrujú veľkosť investície (v EUR) do jednotlivých položiek podľa tabuľky.

Druh investície	**Odhad výnosu**	**Premenná**
Bežné akcie	4%	x_1
Preferované akcie	7%	x_2
Podnikové dlhopisy	11%	x_3
Štátne dlhopisy	6%	x_4
Úspory v banke	5%	x_5

Účelová funkcia (maximalizácia odhadovaného ročného výnosu):

$$J(\mathbf{x}) = 0.04x_1 + 0.07x_2 + 0.11x_3 + 0.06x_4 + 0.05x_5 \quad \rightarrow \quad \max\,.$$

Ohraničenia:

1) Celková investícia:

$$x_1 + x_2 + x_3 + x_4 + x_5 \leq 10\,000\,000$$

2) Celková suma investícií do akcií:

$$x_1 + x_2 \leq 2\,500\,000$$

3) Štátne dlhopisy nesmú byť menšie než úspory v banke:

$$x_4 \geq x_5$$

4) Suma investícií do dlhopisov nesmie presiahnuť polovicu všetkých investovaných prostriedkov:

$$x_3 + x_4 \leq 0.5\,(x_1 + x_2 + x_3 + x_4 + x_5)$$

5) Nezápornosť premenných:

$$x_i \geq 0 \quad \text{pre } i = 1, \ldots, 5$$

Postup riešenia

1. Implementujte účelovú funkciu (maximalizácia výnosu) a všetky ohraničenia príkladu. Keďže `genetic_all`/Genetic Toolbox pracuje s **minimizáciou**, hodnotu maximalizačnej funkcie v implementácii **otočte** tak, aby GA minimalizoval.

2. Implementujte tri metódy pokutovania z prednášky: **mŕtva**, **stupňovitá** a **úmerná**. Pokuty zapracujte do fitness tak, aby ovplyvňovali priebeh konvergencie pri porušení ohraničení. Zvolený tvar pokuty a prípadné parametre pokutovania pre každú metódu v správe **jasne uveďte a stručne zdôvodnite**.

3. Odlaďte **jedno spoločné nastavenie GA** (rovnaké parametre a rovnaké operátory) tak, aby na tomto probléme štandardne konvergovalo rýchlo a malo dobrú opakovateľnosť. Toto nastavenie potom používajte **rovnako** pre všetky tri metódy pokutovania.

4. Pre **každý** typ pokutovania spustite GA **minimálne 5-krát**. Pre každý typ vytvorte **samostatný** graf „fitness vs. generácia“, kde budú zobrazené **všetky behy** a v legende bude pri každom behu uvedená aj **finálna hodnota fitness v zátvorke**.

5. Pre každý typ pokutovania určte **najlepší beh** a uložte jeho výslednú alokáciu $(x_1, \ldots, x_5)$, finálnu hodnotu fitness, hodnotu výnosu a "kontrolu splnenia ohraničení".

6. Vytvorte **finálny porovnávací graf**, kde budú porovnané **najlepšie priebehy** (po jednom) pre mŕtvu, stupňovitú a úmernú pokutu.

7. Výsledky aj program archivujte pre potreby prezentácie.

Poznámka: Cieľom nie je ladiť genetický algoritmus osobitne pre každú metódu pokutovania. Zvoľte jedno spoločné, rozumné nastavenie GA pre daný problém a to potom bez zmeny používajte pri mŕtvej, stupňovitej aj úmernej pokute, aby bolo porovnanie metód férové.

Odovzdanie a hodnotenie

Hodnotenie zadania prebieha formou osobnej konzultácie. Zadanie sa odovzdáva spravidla **na začiatku cvičenia** po odprezentovaní nasledujúceho zadania.
Počas semestra môže študent nahradiť najviac **dve** cvičenia. V takom prípade je možné zadanie odovzdať aj na cvičení, na ktorom študent nahrádza. V ostatných prípadoch sa zadanie odovzdáva vždy **svojmu cvičiacemu**.

Dokumentácia výsledkov (PDF)

Pripravte si stručnú správu (napr. MS Word / PDF), ktorá bude obsahovať grafy z viacerých spustení. Dokument slúži ako podklad pre diskusiu, aby nebolo nutné čakať na opakované výpočty počas obhajoby zadania.

Grafy musia byť exportované v dostatočnej kvalite (nie formou screenshotov grafov) a musia obsahovať názov grafu, popisy osí, legendu (ak je relevantná) a čitateľné mierky. Neodovzdávajte obrázky bez označenia alebo s nečitateľným textom.

V prípade Matlabu je vhodné ukladať celý figure (napr. vo formáte .fig) a následne ho korektne exportovať do obrázka alebo PDF. V prípade Pythonu postupujte obdobne – grafy generujte a ukladajte priamo z prostredia (napr. ako PNG alebo PDF v dostatočnom rozlíšení), nie formou screenshotov.

Pre toto zadanie uveďte v správe: (1) tri samostatné grafy „fitness vs. generácia“ pre **mŕtvu, stupňovitú a úmernú** pokutu, pričom pre každý typ musí byť zobrazených **minimálne 5 behov** a v legende musí byť pri každom behu aj **finálna hodnota fitness v zátvorke**, (2) **finálny porovnávací graf** s **najlepšími priebehmi** pre každú z troch metód pokutovania, (3) pre každú metódu pokutovania **najlepší nájdený výsledok** $(x_1, \ldots, x_5)$, zodpovedajúcu hodnotu výnosu a **kontrolu splnenia ohraničení**, (4) stručnú diskusiu rozdielov medzi metódami pokutovania a dôvodov, prečo pri rovnakom nastavení GA vychádzajú odlišné priebehy a výsledky.

Obhajoba riešenia

Súčasťou hodnotenia je demonštrácia funkčného kódu a vysvetlenie implementácie. Body sa udeľujú najmä za porozumenie princípu algoritmu a schopnosť zdôvodniť dosiahnuté výsledky, nie iba za spustiteľný program.

Pri obhajobe vysvetlite hlavné rozdiely medzi tromi metódami pokutovania (mŕtva, stupňovitá, úmerná) a zdôvodnite, ktorá z nich sa v experimentoch správala najlepšie a ktorá najhoršie. Na základe grafov **fitness vs. generácia** vysvetlite, ako a prečo sa líši tvar priebehov konvergencie pri jednotlivých metódach pokutovania, a ako tieto rozdiely súvisia so spôsobom, akým je pokuta zapracovaná do fitness.

Odporúčané nástroje a technická realizácia

Zadanie je možné vypracovať v prostredí **Matlab** (dostupná licencia STU) alebo v jazyku **Python**.
Ako alternatívu bez inštalácie je možné použiť **MATLAB Online** (`https://matlab.mathworks.com/`). Pre Python odporúčame **Google Colab** (`https://colab.research.google.com/`).

Matlab

Použite dodané súbory a odporúčané príkazy na vizualizáciu podľa pokynov na cvičení. Všetky potrebné materiály, ako napríklad „Genetic Toolbox pre Matlab“, „Testovacia funkcia – testfn3c.m“ a ďalšie súbory, sú dostupné v AIS v dokumentoch k predmetu UMINT.

Python

Ak sa rozhodnete pre Python, odporúčame využiť knižnice `NumPy` a `Matplotlib`. Pre interaktívne zobrazenie (napr. zobrazenie hodnoty pri ukázaní na bod v grafe) môžete použiť `plotly` alebo doplnok `mplcursors` pre Matplotlib.

Oficiálne repozitáre predmetu:

- **Organizácia (prehľad):** `https://github.com/STU-FEI-OUI`
- **Zadania a kódy pre GA blok:** `https://github.com/STU-FEI-OUI/UMINT-GA`
- **Genetic Toolbox:** `https://github.com/STU-FEI-OUI/Genetic-toolbox`

Teoretické poznámky

Formulácia úlohy, obmedzenia a význam fitness

Vektor rozhodovacích premenných $\mathbf{x} = (x_1, \ldots, x_5)$ predstavuje konkrétnu alokáciu kapitálu medzi produkty. Pri genetickom algoritme je dôležité rozlišovať medzi tým, čo je **cieľ** (výnos), a tým, čo algoritmus reálne **optimalizuje** (fitness). Fitness môže obsahovať viac zložiek, pričom cieľová časť vyjadruje „čo chceme“, a pokuty vyjadrujú „čo nesmie alebo nemá nastať“. Vizuálny rozdiel medzi definičným priestorom a prípustnou oblasťou je znázornený na Obr. 1.

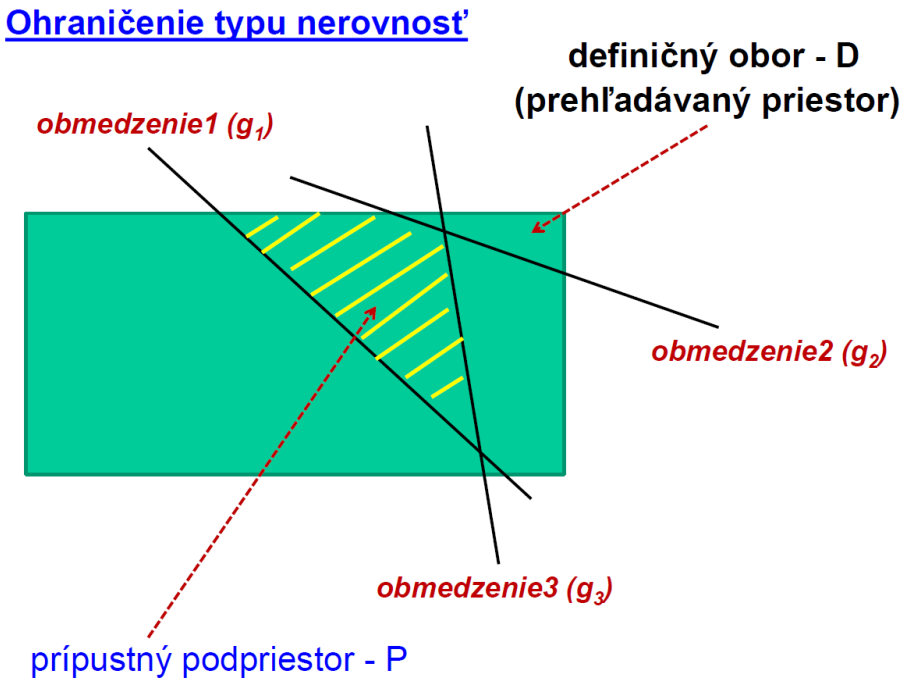

Obr. 1: Definičný priestor a prípustný podpriestor pri nerovnostných obmedzeniach (vizuálna pomôcka k ohraničeniam).

Obmedzenia určujú, ktoré riešenia sú realizovateľné. Rovnostné obmedzenia typicky „zužujú“ priestor riešení výraznejšie než nerovnosti, pretože viažu premenné do jednej presnej bilancie. Nerovnostné obmedzenia vytvárajú hranice prípustnej oblasti. V evolučných algoritmoch existujú dva základné prístupy, ako sa s obmedzeniami vysporiadať. Buď sa neprípustné riešenia priamo opravujú alebo generujú tak, aby nevznikli, alebo sa neprípustnosť odráža v penalizovanej fitness pomocou pokút. V tejto úlohe je kľúčový práve druhý prístup.

V literatúre sa úlohy často formulujú ako maximalizácia úžitku. Implementácie GA však typicky minimalizujú fitness. To znamená, že je potrebné zvoliť konzistentnú transformáciu (napr. otočenie znamienka cieľovej funkcie) a pri interpretácii výsledkov si ustrážiť, či reportujete „výnos“ alebo „fitness“. Pri diskusii sa často pletie situácia, keď sa zlepší penalizovaná fitness, ale neznamená to automaticky vyšší výnos. Je preto vhodné pracovať s oboma číslami, pričom každé má iný význam.

Pokutovanie a interpretácia rôznych prístupov

Pokutovanie umožňuje preložiť obmedzenia do jedného číselného kritéria. V praxi sa často používa viacero pokút naraz, pričom každá reprezentuje iný typ pravidla. Užitočné je uvažovať o pravidlách v troch kategóriách. Kritické porušenia, ktoré sú neprijateľné. Menej kritické porušenia, ktoré síce môžu nastať, ale majú byť nevýhodné. A cieľová časť, ktorú chceme optimalizovať.

Reálny príklad (jazda auta z bodu A do bodu B). Predstavte si, že cieľ je prejsť trasu rýchlo, ale bezpečne. Náraz je stav, ktorý je neprijateľný. Prekročenie rýchlosti alebo krátke vybočenie z pruhu je nežiadúce správanie, ktoré môže mať rôznu závažnosť. Zlepšovanie času jazdy alebo znižovanie vzdialenosti k cieľu je cieľová časť. Pokutovanie sa v tomto kontexte dá chápať ako spôsob, ako určiť, ktoré typy porušení majú byť potláčané okamžite a ktoré majú byť potláčané postupne podľa miery porušenia. To isté sa deje aj v tejto úlohe, len namiesto bezpečnostných pravidiel pracujete s finančnými obmedzeniami.

V tejto úlohe sa porovnávajú tri prístupy. Pri **mŕtvej pokute** dostane riešenie pri porušení ohraničenia **jednu veľkú fixnú pokutu**, ktorá má neprípustné riešenie výrazne znevýhodniť, teda prakticky „zabiť“ v selekcii. Zmyslom tohto prístupu je, aby GA jasne preferoval prípustné riešenia. Zvolená pokuta však má byť **veľká, ale nie extrémna** — napríklad rádovo 10000 alebo iná podobne výrazná hodnota podľa škály fitness, nie nekonečno ani numericky absurdne vysoké čísla. Príliš extrémna pokuta by mohla zbytočne deformovať správanie algoritmu a sťažiť hľadanie prípustnej oblasti.

Pri **stupňovitej pokute** sa používa **fixná pokuta za stupeň porušenia**, pričom stupeň porušenia môže byť určený napríklad počtom porušených ohraničení. Takýto prístup znamená, že ak je porušené jedno ohraničenie, pripočíta sa jedna pevná pokuta, ak sú porušené dve ohraničenia, pripočítajú sa dve pevné pokuty atď. Napríklad pri fixnej pokute 5000 môže riešenie s dvomi porušenými ohraničeniami dostať pokutu $5000 \cdot 2$. Tento prístup teda nerozlišuje len medzi prípustným a neprípustným riešením, ale aj medzi „menej zlým“ a „viac zlým“ neprípustným riešením podľa počtu porušení.

Pri **úmernej pokute** sa veľkosť pokuty viaže na mieru porušenia ohraničenia. Čím viac riešenie prekračuje povolenú hranicu alebo čím viac sa odchyľuje od požadovanej hodnoty, tým väčšiu pokutu dostane. Takáto metóda poskytuje algoritmu jemnejšiu informáciu o tom, ako ďaleko je riešenie od prípustnej oblasti.

Pri pokutách je rozhodujúca ich relatívna veľkosť voči cieľovej časti. Ak je pokuta príliš malá, algoritmus môže preferovať riešenia s vysokým výnosom aj napriek porušeniu obmedzení. Ak je pokuta príliš veľká, algoritmus môže uprednostňovať „bezpečné“ riešenia bez ohľadu na výnos, alebo sa správanie algoritmu môže stať nestabilné. Pri porovnávaní prístupov preto sledujte, či sa mení nielen kvalita výsledku, ale aj stabilita medzi behmi, a tieto pozorovania prepojte so spôsobom, akým je pokuta definovaná.

Porovnávanie metód a čítanie grafov konvergencie

Aby bolo porovnanie férové, mení sa iba metóda pokutovania a ostatné nastavenia GA ostávajú rovnaké. V opačnom prípade sa nedá rozlíšiť, či rozdiely spôsobil iný výber, iná mutácia alebo samotné pokutovanie. Rovnaké nastavenie GA zároveň zvýrazní to, že jednotlivé prístupy môžu mať odlišné nároky na citlivosť parametrov. Toto je legitímna časť diskusie, nie chyba.

Grafy „fitness vs. generácia“ slúžia na pochopenie správania algoritmu. Pri porovnávaní metód si všímajte, či je zlepšovanie plynulé alebo nepravidelné, ako rýchlo nastane zlepšenie, či sa behy medzi sebou výrazne rozchádzajú, a či sa zlepšovanie časom spomaľuje alebo zastaví. V obhajobe sa očakáva interpretácia toho, čo vidno v grafoch, a prepojenie na to, ako je fitness zložená a akým spôsobom sú v nej zapracované pokuty.