

Umelá inteligencia Zadanie 5

Laushkin Ivan

Cieľ úlohy

Precvičte si dve demonštračné úlohy s MLP sieťou: (a) klasifikáciu bodov do tried a (b) aproximáciu nelineárnej funkcie. Programy a dáta k úlohám sú dostupné v AIS a v repozitároch predmetu (github). Ako doplnkový príklad/ukážka na klasifikáciu môžete použiť aj dataset IRIS, ktorý je dostupný v AIS a v repozitároch predmetu.

Uloha 5a

Navrhňte a natrénujte MLP sieť, ktorá klasifikuje body do 5 tried na základe vstupov x , y , z . Cieľom je nájsť čo najjednoduchšiu sieť (najmenší počet neurónov v skrytej vrstve) pri zachovaní čo najlepšej klasifikácie.

Pre riešenie klasifikácie bola zvolená nasledovná konfigurácia:

- **Vstupná vrstva:** 3 neuróny (súradnice x , y , z).
- **Skrytá vrstva:** 15 neurónov s aktivačnou funkciou **ReLU**.
- **Výstupná vrstva:** 5 neurónov (každý pre jednu triedu).
- **Chybová funkcia (Loss):** Cross-Entropy Loss.
- **Optimalizátor:** Adam (Learning Rate = 0.01).
- **Počet epoch:** 200.

Počas procesu učenia hodnota chybovej funkcie (Loss) úspešne klesla z počiatočných **1.43** na finálnych **0.17**. Pri testovaní na vybraných bodoch sieť správne priradila triedy, čo svedčí o úspešnej separácii príznakového priestoru.

Epoch [20/200], Loss: 1.4300

Epoch [40/200], Loss: 1.1255

Epoch [60/200], Loss: 0.7918

Epoch [80/200], Loss: 0.5541

Epoch [100/200], Loss: 0.4105

Epoch [120/200], Loss: 0.3214

Epoch [140/200], Loss: 0.2620

Epoch [160/200], Loss: 0.2202

Epoch [180/200], Loss: 0.1897

Epoch [200/200], Loss: 0.1668

Uloha 5b

Navrhňte a natrénujte MLP sieť, ktorá aproximuje nelineárnu funkciu $y = f(x)$ na základe meraných dát. Cieľom je dosiahnuť malú odchýlku na testovacích dátach a zároveň použiť čo najjednoduchšiu sieť.

Pri prvom pokuse o trénovanie na surových dátach vykazoval model známky **podučenia (underfitting)** – predikovaná krivka bola príliš vyhladená a nereagovala na prudké zmeny v dátach. Pre dosiahnutie uspokojivých výsledkov boli vykonané tieto úpravy:

1. **Normalizácia dát:** Použitie metódy StandardScaler na transformáciu vstupov x a výstupov y do porovnateľného rozsahu.
2. **Úprava architektúry:** Pridanie druhej skrytej vrstvy pre lepšiu schopnosť siete zachytiť nelinearity.
3. **Zvýšenie počtu iterácií:** Počet epoch bol zvýšený na 3000 pre zabezpečenie konvergenzie algoritmu.

Finálna architektúra a parametre

- **Vstupná vrstva:** 1 neurón (x).
- **Skryté vrstvy:** 2 vrstvy po 25 neurónov s funkciou **Tanh**.
- **Výstupná vrstva:** 1 neurón (lineárny výstup).
- **Chybová funkcia:** MSE (Mean Squared Error).
- **Optimalizátor:** Adam.

Po implementácii normalizácie a úprave hyperparametrov sieť úspešne approximovala funkciu. Výsledná predikovaná krivka kopíruje trend trénovacích dát s minimálnou strednou kvadratickou chybou.

Epoch [500/3000], Loss (MSE): 0.068439

Epoch [1000/3000], Loss (MSE): 0.019672

Epoch [1500/3000], Loss (MSE): 0.011526

Epoch [2000/3000], Loss (MSE): 0.011111

Epoch [2500/3000], Loss (MSE): 0.010078

Epoch [3000/3000], Loss (MSE): 0.009273

